

Apêndices — Sistema de Recuperação de Informação Híbrido

Luiz Fernando Postingel Quirino¹

¹Faculdade de Computação – Universidade Federal de Mato Grosso do Sul (UFMS)
Campo Grande – MS – Brasil

luiz.quirino@ufms.br

Apêndice A: Average Precision por consulta

A Tabela ?? traz a AP de cada sistema por consulta. O denso pontua perto de zero em consultas como q12 e q15, onde os documentos que ele recupera não constam como relevantes no gabarito — evidência do viés de pooling discutido no relatório.

Tabela 1. Average Precision (AP) por consulta.

qid	BM25	KNN	Denso	RRF	M1	M3
q01	0.782	0.693	0.272	0.630	0.891	0.647
q02	0.590	0.738	0.189	0.448	0.734	0.571
q03	0.759	0.692	0.294	0.683	0.824	0.478
q04	0.813	0.676	0.349	0.702	0.855	0.484
q05	0.850	0.758	0.203	0.570	0.909	0.401
q06	0.750	0.423	0.200	0.606	0.759	0.344
q07	0.729	0.436	0.028	0.392	0.714	0.282
q08	0.788	0.720	0.301	0.661	0.886	0.525
q09	0.927	0.895	0.190	0.555	0.977	0.445
q10	0.713	0.805	0.154	0.614	0.795	0.753
q11	1.000	0.982	0.012	0.595	1.000	0.810
q12	0.952	0.798	0.001	0.433	0.954	0.864
q13	1.000	0.700	0.250	0.532	0.833	1.000
q14	0.959	0.919	0.253	0.705	0.987	0.672
q15	0.841	0.861	0.000	0.149	0.841	0.841

Apêndice B: Otimização do BM25 (M4)

Grid search de k_1 e b , com MAP no conjunto de avaliação. A melhor configuração ($k_1 = 2,0$, $b = 0,5$) eleva o MAP de 0,830 (padrão) para 0,851.

Tabela 2. MAP por configuração do BM25.

k_1	b	MAP	k_1	b	MAP	k_1	b	MAP
1.2	0.50	0.817	1.5	0.50	0.829	2.0	0.50	0.851
1.2	0.75	0.816	1.5	0.75	0.830	2.0	0.75	0.831
1.2	1.00	0.781	1.5	1.00	0.774	2.0	1.00	0.782

Apêndice C: Agrupamento dos resultados (M2)

Para a consulta “lei 14133 compras públicas tecnologia”, o K-means sobre o top-30 (espaço dos embeddings) escolheu $k = 2$ pela silhueta. As facetas, descritas pelos termos mais frequentes de cada grupo:

- **Grupo 0 (marco legal e processo):** público, lei, compra, processo, contrato, licitação.
- **Grupo 1 (tecnologia e sustentabilidade):** compra, público, análise, tecnologia, sustentável, federal.

Apêndice D: Escopo expandido da coleção

As bases governamentais mapeadas (PNCP, Compras.gov.br, TCU, LexML) e os pareceres obtidos via LAI não entram nesta coleção. Elas são o corpus-alvo da etapa de mes-trado, quando o foco deixa de ser artigos científicos e passa a ser peças processuais reais. Esses documentos têm uma natureza própria: o PNCP e os sistemas de compras entregam cada processo com um número variável de artefatos, que muda conforme o trâmite. Os resumos e textos introdutórios não seguem padronização real, o que abre espaço para in-ferências erradas na automação. É aí que o aprendizado semissupervisionado faz sentido: rotular tudo à mão é inviável pelo tamanho do conjunto, então parte-se de poucos rótulos e propaga-se o aprendizado para o resto.

O campo identificador de cada documento chama-se `arxiv_id`. O nome é herança do material de apoio do professor (o notebook de coleta do arXiv). Mantive-mos o nome por compatibilidade, mas ele guarda o id da fonte de origem: id do arXiv para artigos do arXiv, id da OpenAlex (prefixo `W`) para a OpenAlex e id da BDTD para as teses. Um campo `source` registra a proveniência de cada documento.

Os resultados completos por consulta, o pool de revisão e os runs TREC estão disponíveis no repositório: <https://github.com/luizfpq/ufms-facom-ia-2026.1-t1>