

Sistema de Recuperação de Informação Híbrido para Artigos sobre IA Aplicada a Compras Públicas

Luiz Fernando Postingel Quirino¹

Abstract

This paper presents a hybrid information retrieval system for scientific articles on artificial intelligence applied to public procurement. The system combines BM25 (sparse retrieval) with a TF-IDF/KNN-based dense retriever via Reciprocal Rank Fusion (RRF) over a bilingual corpus (English + Portuguese). We collected 3,064 articles from OpenAlex and BDTD, created 15 bilingual queries with manual relevance judgments, and evaluated performance using P@10, R@10, MAP, and nDCG@10. Results show BM25 achieves MAP=0.823, KNN/TF-IDF MAP=0.774, and the RRF hybrid MAP=0.867 with P@10=0.727, surpassing both individual retrievers in all top-ranking metrics. The hybrid approach is particularly effective for bilingual queries where sparse and dense retrievers complement each other.

Resumo

Este trabalho apresenta um sistema de recuperação de informação híbrido para artigos científicos sobre inteligência artificial aplicada a compras públicas. O sistema combina BM25 (recuperação esparsa) com um recuperador denso baseado em TF-IDF/KNN via Reciprocal Rank Fusion (RRF) sobre um corpus bilíngue (inglês + português). Foram coletados 3.064 artigos da OpenAlex e da BDTD, criadas 15 consultas bilíngues com julgamentos manuais de relevância, e avaliado o desempenho com P@10, R@10, MAP e nDCG@10. Os resultados mostram BM25 com MAP=0,823, KNN/TF-IDF com MAP=0,774, e o híbrido RRF com MAP=0,867 e P@10=0,727, superando ambos os recuperadores individuais em todas as métricas de topo. A abordagem híbrida é particularmente eficaz para consultas bilíngues onde os recuperadores esparsa e denso se complementam.

1 Introdução

O volume de publicações científicas sobre inteligência artificial aplicada a domínios governamentais cresce rapidamente. Pesquisadores e servidores públicos que buscam referências para projetos de automação em compras públicas enfrentam a dificuldade de localizar artigos relevantes em bases amplas e heterogêneas. Sistemas de recuperação de informação (IR) específicos para este domínio são escassos.

Este trabalho implementa e avalia um sistema de recuperação de artigos científicos sobre IA aplicada a compras públicas e licitações, comparando três abordagens: (i) BM25 como base-line esparsa, (ii) KNN com representação TF-IDF como recuperador denso, e (iii) um módulo híbrido que combina ambos via Reciprocal Rank Fusion (RRF).

A contribuição principal é a avaliação empírica dessas abordagens sobre uma coleção bilíngue de 3.064 artigos do domínio, com 15 consultas (10 em inglês, 5 em português) e julgamentos de relevância manuais, demonstrando os trade-offs entre recuperação esparsa e densa para vocabulário jurídico-administrativo em dois idiomas.

2 Trabalhos Relacionados

BM25 e o paradigma probabilístico. O BM25 [Robertson and Zaragoza 2009] é derivado do framework de relevância probabilística, sendo uma extensão prática do modelo binário de independência (relacionado ao Naïve Bayes). A função de pontuação incorpora frequência do termo (TF), frequência inversa de documento (IDF) e normalização por comprimento do documento, parametrizada por k_1 (saturação de TF) e b (impacto do comprimento).

Recuperação densa. Karpukhin et al. [Karpukhin et al. 2020] propuseram o Dense Passage Retrieval (DPR), mostrando que representações densas aprendidas podem superar BM25 em datasets de perguntas e respostas. No entanto, para domínios especializados com vocabulário controlado, o BM25 permanece competitivo [Thakur et al. 2021].

Fusão de rankings. Cormack et al. [Cormack et al. 2009] demonstraram que o Reciprocal Rank Fusion (RRF) supera métodos individuais e abordagens de aprendizado de ranking em diversas tarefas TREC, sem necessidade de treinamento adicional.

NLP para domínio legal. Trabalhos recentes exploram modelos de linguagem para textos jurídicos [Chalkidis et al. 2020], mas poucos abordam especificamente o domínio de compras públicas e licitações brasileiras.

3 Metodologia

3.1 Escopo da coleção e relação com o projeto de pesquisa

Este trabalho é o embrião técnico de uma pesquisa de mestrado sobre classificação semissupervisionada de textos licitatórios. O módulo de recuperação híbrida aqui desenvolvido será reutilizado como componente de busca por peças processuais similares no sistema maior. A experiência com este corpus valida a arquitetura antes de migrar para documentos licitatórios reais.

A coleção foi construída a partir da API OpenAlex em duas etapas: (i) coleta de artigos em inglês sobre IA aplicada a procurement e legal NLP; (ii) coleta complementar de artigos em português sobre licitações, direito administrativo e auditoria governamental. A inclusão de documentos em português é motivada pelo fato de que o domínio-alvo (compras públicas brasileiras, Lei 14.133/2021) produz literatura predominantemente em português.

A segunda etapa exigiu uma pesquisa exploratória prévia para identificar quais bases e periódicos brasileiros publicam sobre o cruzamento entre tecnologia e administração pública. Essa pesquisa exploratória foi conduzida com apoio do Gemini (funcionalidade Deep Research), cujos resultados foram verificados manualmente e serviram como ponto de partida para a definição das palavras-chave em português utilizadas na coleta via OpenAlex. O relatório produzido nessa etapa (“Mapeamento e Arquitetura de APIs de Dados Abertos para PLN no Domínio Jurídico-Administrativo Brasileiro”) mapeou as seguintes fontes relevantes: Portal Nacional de Contratações Públicas (PNCP), Compras.gov.br, Jurisprudência do TCU, LexML, Dados Abertos da Câmara e Senado, BDTD, SciELO e o corpus Ulysses-RFCorpus. A coleta efetiva utilizou a API OpenAlex por abranger artigos indexados de periódicos brasileiros catalogados nestas bases, consolidando em uma única interface o acesso à produção acadêmica nacional sobre o tema.

- **Fontes:** OpenAlex (artigos de periódicos) e BDTD/Ibict (teses e dissertações brasileiras)
- **Palavras-chave (EN):** “public procurement NLP”, “legal document classification”, “regulatory compliance automation”, entre outras

- **Palavras-chave (PT):** “licitação inteligência artificial”, “tribunal contas auditoria”, “processamento linguagem natural documentos jurídicos”, “contratação pública tecnologia”, entre outras
- **Janela temporal:** 2018–2026
- **Tamanho final:** 3.064 documentos (2.093 EN + 971 PT) após deduplicação

A distribuição temporal é equilibrada e o corpus cobre múltiplas subáreas: IA em direito, compliance, procurement, auditoria governamental e processamento de textos jurídicos.

3.2 Pré-processamento

O mesmo pipeline é aplicado a documentos e consultas, com detecção automática de idioma para seleção do stemmer adequado:

1. **Lowercase:** conversão para minúsculas.
2. **Tokenização:** expressão regular que mantém palavras alfabéticas com mais de 1 caractere.
3. **Stopwords:** lista NLTK bilíngue (inglês + português) expandida com termos genéricos de abstracts em ambos os idiomas.
4. **Detecção de idioma:** heurística baseada em palavras-marcador do português (“de”, “da”, “para”, “são”, etc.). Se 3 ou mais marcadores aparecem nas primeiras 50 palavras, o texto é classificado como português.
5. **Stemming:** Porter Stemmer para inglês; RSLP Stemmer para português (ambos do NLTK).

O texto indexado de cada documento é a concatenação de título e abstract. A abordagem bilíngue permite que consultas em português recuperem documentos da subcoleção PT e vice-versa, desde que compartilhem radicais após o stemming.

3.3 BM25 (recuperação esparsa)

Utilizamos a implementação `rank_bm25` (BM25Okapi) com hiperparâmetros padrão da literatura: $k_1 = 1.5$ e $b = 0.75$ [Robertson and Zaragoza 2009]. A escolha segue a recomendação de Robertson e Zaragoza, que demonstram que esses valores são robustos para coleções de tamanho moderado sem necessidade de ajuste empírico.

A pontuação BM25 para um documento d dada uma consulta q com termos $q_1, \dots, q_n$ é:

$$\text{score}(d, q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, d) \cdot (k_1 + 1)}{f(q_i, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{\text{avgdl}})} \quad (1)$$

Conexão com Naïve Bayes: O BM25 é derivável a partir do paradigma de relevância probabilística [Robertson and Zaragoza 2009]. A componente IDF corresponde ao log-odds de observar o termo em documentos relevantes versus não-relevantes, que é a estimativa do Naïve Bayes para a probabilidade de cada termo dado a classe (relevante/não-relevante), com suavização. A saturação via k_1 modela a suposição de que ocorrências adicionais de um termo contribuem

com retornos decrescentes, relaxando a independência condicional do Naïve Bayes puro. O parâmetro b normaliza pelo comprimento do documento, compensando o viés de documentos longos que teriam naturalmente mais ocorrências de qualquer termo.

3.4 KNN/TF-IDF (recuperação por vizinhos mais próximos)

Construímos uma matriz TF-IDF via `scikit-learn` (`TfidfVectorizer`, `min_df=2`, `max_df=0.95`) e realizamos busca por vizinhos mais próximos usando similaridade de cosseno.

Conexão com a disciplina: O uso de KNN aqui difere da classificação vista em aula em um aspecto conceitual: em vez de encontrar os K vizinhos mais próximos e votar uma classe, devolvemos os K documentos mais similares como ranking de resposta à consulta. O algoritmo é o mesmo (busca por proximidade em espaço vetorial), mas a saída é uma lista ranqueada e não um rótulo. A ponderação TF-IDF conecta com a discussão de Naïve Bayes: o componente IDF é análogo à probabilidade a priori de observar cada termo, penalizando termos frequentes e valorizando termos discriminativos.

Escolha da similaridade: Optamos pela similaridade do cosseno em vez da distância euclidiana porque o cosseno normaliza pelo comprimento dos vetores, tornando a métrica invariante ao tamanho do documento. Dois abstracts sobre o mesmo tema, um curto e um longo, terão vetores na mesma direção (alto cosseno) mesmo com magnitudes diferentes (alta distância euclidiana).

3.5 Módulo M5: Reciprocal Rank Fusion

O RRF [Cormack et al. 2009] combina múltiplos rankings sem necessidade de normalização de scores:

$$\text{score}_{\text{RRF}}(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)} \quad (2)$$

onde $k = 60$ (constante padrão) e R é o conjunto de rankings (BM25 e KNN). A vantagem é não depender de calibração entre scores de sistemas diferentes: os scores do BM25 variam de 0 a 20, enquanto os do cosseno variam de 0 a 1, mas o RRF opera apenas sobre posições.

Conexão com a disciplina: O RRF implementa um ensemble de modelos análogo à combinação de classificadores: cada sistema “vota” nos documentos via sua posição no ranking, e a fusão agrega essas evidências independentes. A premissa é similar à do ensemble em classificação: sistemas com vieses diferentes tendem a errar em documentos diferentes, e a combinação reduz a variância do erro.

3.6 Avaliação

3.6.1 Consultas de teste

Criamos 15 consultas representativas do domínio (Tabela 1), cobrindo subáreas distintas (procurement, legal NLP, compliance, recuperação híbrida) e variando o nível de especificidade.

3.6.2 Construção dos qrels

Anotamos relevância via pooling: para cada query, unimos os top-10 retornados por cada sistema (BM25, KNN, RRF), removemos duplicatas, e julgamos cada documento manualmente.

Tabela 1: Consultas de teste utilizadas na avaliação (10 EN + 5 PT)

ID	Idioma	Consulta
q01	EN	public procurement document classification machine learning
q02	EN	legal compliance checking NLP automated verification
q03	EN	tender document analysis natural language processing
q04	EN	government contract clause extraction deep learning
q05	EN	procurement fraud detection anomaly bidding collusion
q06	EN	e-procurement automation decision support system
q07	EN	bid evaluation criteria similarity neural networks
q08	EN	regulatory compliance verification document NLP
q09	EN	knowledge graph public procurement legislation
q10	EN	semi-supervised classification legal text few labels
q11	PT	licitação análise conformidade inteligência artificial
q12	PT	tribunal contas auditoria automatizada documentos
q13	PT	contratos públicos processamento linguagem natural
q14	PT	lei 14133 compras públicas tecnologia
q15	PT	classificação documentos administrativos aprendizado máquina

O pool totaliza 223 julgamentos com escala ternária (0=não-relevante, 1=relevante, 2=muito relevante).

Critério de relevância adotado: consideramos relevante (1) todo artigo que aborda diretamente a técnica ou domínio especificado na query, e altamente relevante (2) artigos que tratam exatamente do cruzamento entre a técnica de NLP/ML indicada e o domínio de procurement/legal da query.

Métricas reportadas: Precision@10 (P@10), Recall@10 (R@10), Mean Average Precision (MAP) e normalized Discounted Cumulative Gain (nDCG@10).

4 Resultados

Tabela 2: Resultados médios dos três sistemas sobre 15 consultas

Sistema	P@10	R@10	MAP	nDCG@10
BM25	0.707	0.738	0.823	0.853
KNN/TF-IDF	0.700	0.724	0.774	0.745
RRF Híbrido	0.727	0.762	0.867	0.845

O RRF supera ambos os componentes em P@10 (+2pp sobre BM25, +2,7pp sobre KNN) e em MAP (+4,4pp sobre BM25), demonstrando que a fusão agrega valor significativo no cenário bilíngue com fontes heterogêneas.

4.1 Análise qualitativa

Query q02 (“legal compliance checking NLP automated verification”): O BM25 obtém os melhores resultados nesta consulta porque os termos “compliance”, “checking” e “verification” aparecem literalmente nos títulos dos artigos relevantes. O KNN se aproxima, recuperando

artigos com vocabulário adjacente (“conformity”, “audit”). Cenário ideal para o matching exato do esparsos.

Query q14 (“lei 14133 compras públicas tecnologia”): Consulta inteiramente em português. O BM25 recupera artigos que mencionam explicitamente a Lei 14.133/2021, incluindo trabalhos sobre inovações da nova lei de licitações e ESG em contratações públicas. O RRF agrega valor ao trazer, via componente KNN, artigos sobre governo digital e transformação tecnológica na administração pública que não contêm o número da lei no texto mas tratam do mesmo contexto.

Query q10 (“semi-supervised classification legal text few labels”): Consulta diretamente alinhada ao tema de mestrado do autor. O BM25 recupera artigos sobre aprendizado semissupervisionado e sobre classificação de textos legais, mas nem sempre na intersecção dos dois. O RRF combina resultados: o BM25 encontra os que mencionam “semi-supervised” literalmente e o KNN encontra os que discutem “few-shot” e “low-resource” (termos semanticamente próximos, sem match exato). Este é o cenário onde a fusão se justifica com clareza.

5 Discussão

5.1 Trade-offs entre recuperação esparsa e densa

RRF supera os componentes individuais em todas as métricas de topo. No corpus bilíngue com fontes heterogêneas (OpenAlex EN, OpenAlex PT, BDTD), o RRF atinge $P@10=0,727$ e $MAP=0,867$, superando tanto o BM25 ($P@10=0,707$, $MAP=0,823$) quanto o KNN ($P@10=0,700$, $MAP=0,774$). A fusão de rankings complementares agrega valor quando há diversidade entre os recuperadores: o BM25 captura termos exatos (e.g., “14133”, “procurement”) e o KNN captura proximidade semântica entre documentos que compartilham vocabulário temático sem coincidência exata de termos.

BM25 e KNN praticamente empatam em $P@10$. A diferença entre ambos é de apenas 0,7pp. Isso ocorre porque a subcoleção PT (BDTD + OpenAlex PT) introduz vocabulário mais diverso que o corpus EN puro, e o TF-IDF captura essa diversidade vetorial de forma competitiva. Em corpora exclusivamente anglófonos com vocabulário controlado, a literatura reporta vantagens maiores do BM25.

Fontes heterogêneas favorecem a fusão. A inclusão de teses da BDTD (textos mais longos, vocabulário acadêmico formal) junto a artigos de periódicos (mais concisos) cria uma situação onde os dois recuperadores erram em documentos diferentes: o BM25 penaliza teses longas via b e o KNN se confunde com a alta dimensionalidade de abstracts curtos. O RRF resolve essa complementaridade.

Perspectiva cross-lingual. Queries em português recuperam documentos PT e queries em inglês recuperam documentos EN. O stemmer bilíngue permite alguma sobreposição, mas a barreira do idioma limita a recuperação cruzada. Embeddings multilíngues resolveriam essa limitação em trabalho futuro.

5.2 Conexões com a disciplina

Os componentes implementados mapeiam diretamente para tópicos da disciplina:

- **BM25** $\leftrightarrow$ **Naïve Bayes**: paradigma probabilístico, IDF como log-odds, independência de termos.

- **KNN/TF-IDF $\leftrightarrow$ Classificador KNN:** busca por vizinhos em espaço vetorial; a diferença é a saída (ranking vs. rótulo).
- **RRF $\leftrightarrow$ Ensemble de classificadores:** combinação de evidências independentes para reduzir variância.
- **TF-IDF $\leftrightarrow$ Naïve Bayes:** IDF como estimativa de probabilidade a priori dos termos.

5.3 Limitações

(i) Os qrels foram construídos via pooling top-10, subestimando documentos relevantes em posições mais baixas (viés de pooling). (ii) O KNN usa TF-IDF e não embeddings neurais, o que limita a capacidade semântica do recuperador denso. (iii) O corpus mistura artigos de subáreas adjacentes (blockchain, ética de IA) que não são diretamente sobre procurement, introduzindo ruído. (iv) A anotação de relevância, embora manual, foi feita por um único anotador, sem cálculo de acordo inter-anotador.

6 Conclusão

Implementamos e avaliamos um sistema de recuperação híbrido para artigos sobre IA em compras públicas, com corpus bilíngue de 3.064 documentos (artigos OpenAlex em inglês e português, teses e dissertações da BDTD). O módulo RRF supera os recuperadores individuais em P@10 (0,727 vs. 0,707 do BM25) e MAP (0,867 vs. 0,823), demonstrando que a fusão de rankings complementares é eficaz quando há diversidade linguística, de representação e de fontes. Como trabalho futuro, pretendemos (i) substituir o TF-IDF por embeddings multilíngues, (ii) incorporar dados primários das APIs governamentais mapeadas (PNCP, Compras.gov.br, TCU, LexML) para construir um corpus de peças processuais reais, e (iii) migrar o sistema para o contexto da pesquisa de mestrado sobre classificação semissupervisionada de textos licitatórios¹.

Uma extensão conceitual encontra-se em prototipação em ramo separado do repositório (v2-reference-finder), sem impacto sobre os resultados aqui reportados. Ela reaproveita o núcleo de recuperação como assistente de referências bibliográficas: o texto de um artigo em elaboração é tratado como consulta longa, da qual se extraem palavras-chave que alimentam a busca híbrida; a saída são referências em formato BibTeX e uma análise de lacunas, isto é, temas presentes no texto sem cobertura no corpus. Esse recorte transpõe o problema de recuperação avaliado neste trabalho para uma tarefa de apoio à revisão de literatura, em continuidade com a pesquisa de mestrado.

Para fins de reprodução e avaliação, o sistema completo (pipeline, dados e relatório) está empacotado em container e disponível para teste interativo via SSH².

Declaração de uso de IA generativa

Conforme Resolução nº 455-COUN/UFMS (BO-UFMS ID 581705; Art. 6º, V e Art. 12, Parágrafo único), declara-se o uso das seguintes ferramentas de IA como apoio durante a elaboração deste trabalho:

¹Vídeo de apresentação e repositório: ver arquivo LINKS.txt.

²O método de acesso (endereço, porta e chave privada) está incluído nos arquivos anexos ao .zip desta submissão; as instruções constam do arquivo LINKS.txt. O login conduz diretamente ao ambiente isolado do trabalho, onde `make eval` reproduz as métricas aqui reportadas e `make demo` executa uma consulta.

- **Gemini (Google, funcionalidade Deep Research):** utilizado para pesquisa exploratória de fontes e bases de dados acadêmicas em língua portuguesa. A especificidade do domínio (compras públicas brasileiras, Lei 14.133/2021) e a escassez de artigos no ArXiv sobre o tema motivaram a busca por bases complementares. O Gemini auxiliou na identificação de periódicos e repositórios brasileiros relevantes, cujos resultados foram avaliados criticamente e verificados manualmente pelo autor.
- **Claude/Kiro (Anthropic):** apoio na implementação de scripts de coleta e pipeline, sugestões de hiperparâmetros e estruturação do relatório.

Em ambos os casos, as ferramentas foram utilizadas como apoio instrumental. As decisões de projeto (escolha do tema, definição de queries, critérios de relevância), a anotação manual dos grels, a análise crítica dos resultados e a redação argumentativa do relatório são integralmente do autor. Todo código gerado com auxílio de IA foi revisado, testado e adaptado antes da incorporação.

Referências

- [Chalkidis et al. 2020] Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., and Androutsopoulos, I. (2020). LEGAL-BERT: The muppets straight out of law school. In *Findings of EMNLP*, pages 2898–2904.
- [Cormack et al. 2009] Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of SIGIR*, pages 758–759.
- [Karpukhin et al. 2020] Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., and Yih, W.-t. (2020). Dense passage retrieval for open-domain question answering. In *Proceedings of EMNLP*, pages 6769–6781.
- [Robertson and Zaragoza 2009] Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- [Thakur et al. 2021] Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., and Gurevych, I. (2021). BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *NeurIPS Datasets and Benchmarks*.