

Sistema de Recuperação de Informação Híbrido para Artigos sobre IA Aplicada a Compras Públicas

Luiz Fernando Postingel Quirino¹

¹Faculdade de Computação – Universidade Federal de Mato Grosso do Sul (UFMS)
Campo Grande – MS – Brasil

luiz.quirino@ufms.br

Abstract. *This paper presents a hybrid information retrieval system for scientific articles on artificial intelligence applied to public procurement. The system combines BM25 (sparse retrieval) with a TF-IDF/KNN-based dense retriever via Reciprocal Rank Fusion (RRF) over a bilingual corpus (English + Portuguese). We collected 3,106 articles from OpenAlex, BDTD, and arXiv, created 15 bilingual queries with manual relevance judgments, and evaluated performance using P@10, R@10, MAP, and nDCG@10. Results show the supervised re-ranking module (M1) achieves the best MAP (0.864), with BM25 a strong baseline (MAP=0.830). The dense retriever scored lower, which we trace to pooling bias in the relevance judgments rather than to the model itself. We discuss how this annotation bottleneck motivates semi-supervised learning for the procurement domain.*

Resumo. *Este trabalho apresenta um sistema de recuperação de informação híbrido para artigos científicos sobre inteligência artificial aplicada a compras públicas. O sistema combina BM25 (recuperação esparsa) com um recuperador denso baseado em TF-IDF/KNN via Reciprocal Rank Fusion (RRF) sobre um corpus bilíngue (inglês + português). Foram coletados 3.106 artigos da OpenAlex, da BDTD e do arXiv, criadas 15 consultas bilíngues com julgamentos manuais de relevância, e avaliado o desempenho com P@10, R@10, MAP e nDCG@10. Os resultados mostram o módulo de re-ranking supervisionado (M1) com o melhor MAP (0,864), e o BM25 como baseline forte (MAP=0,830). O recuperador denso pontuou abaixo, o que atribuímos ao viés de pooling nos julgamentos de relevância, e não ao modelo em si. Discutimos como esse gargalo de anotação motiva o aprendizado semissupervisionado para o domínio.*

1. Introdução

O volume de publicações científicas sobre inteligência artificial aplicada a domínios governamentais cresce rapidamente. Pesquisadores e servidores públicos que buscam referências para projetos de automação em compras públicas enfrentam a dificuldade de localizar artigos relevantes em bases amplas e heterogêneas. Sistemas de recuperação de informação (IR) específicos para este domínio ainda são escassos. Os sistemas de Geração Aumentada por Recuperação (RAG) [Lewis et al. 2020, Gao et al. 2024] atacam esse problema: acoplam um recuperador a um modelo generativo. Mas a qualidade da resposta final depende do recuperador. É o “R” do RAG, e é o objeto deste trabalho.

Este trabalho implementa e avalia um sistema de recuperação de artigos científicos sobre IA aplicada a compras públicas e licitações, comparando três abordagens: (i) BM25

como baseline esparsa, (ii) KNN com representação TF-IDF como recuperador denso, e (iii) um módulo híbrido que combina ambos via Reciprocal Rank Fusion (RRF).

A contribuição principal é empírica. Avaliamos três recuperadores (BM25, KNN/TF-IDF e denso), a fusão híbrida e os módulos de aprofundamento sobre uma coleção bilíngue de 3.106 artigos do domínio, com 15 consultas e julgamentos manuais de relevância. A comparação mostra os trade-offs entre recuperação esparsa, densa e híbrida, e expõe o gargalo da anotação manual de relevância em um domínio nichado e bilíngue.

2. Trabalhos Relacionados

BM25 e o paradigma probabilístico. O BM25 [Robertson and Zaragoza 2009, Manning et al. 2008] é derivado do framework de relevância probabilística, sendo uma extensão prática do modelo binário de independência (relacionado ao Naïve Bayes). A função de pontuação incorpora frequência do termo (TF), frequência inversa de documento (IDF) e normalização por comprimento do documento, parametrizada por k_1 (saturação de TF) e b (impacto do comprimento).

Recuperação densa e fusão. Karpukhin et al. [Karpukhin et al. 2020] mostraram, com o Dense Passage Retrieval, que representações densas aprendidas superam o BM25 em perguntas e respostas, embora o BM25 siga competitivo em domínios de vocabulário controlado [Thakur et al. 2021]. Cormack et al. [Cormack et al. 2009] demonstraram que o Reciprocal Rank Fusion supera métodos individuais sem treino adicional. Lin [Lin 2021] unifica recuperação esparsa, densa e híbrida sob uma visão representacional, o que fundamenta a comparação experimental deste trabalho.

NLP para domínio legal. Trabalhos recentes exploram modelos de linguagem para textos jurídicos [Chalkidis et al. 2020], mas poucos abordam especificamente o domínio de compras públicas e licitações brasileiras.

3. Metodologia

3.1. Escopo da coleção e relação com o projeto de pesquisa

Este trabalho é o embrião técnico de uma proposta de mestrado, ainda em fase de ideia a validar com os orientadores. A proposta trata da classificação semissupervisionada de textos licitatórios para apoio à análise de conformidade em compras públicas. O sistema de recuperação aqui desenvolvido vira, nessa proposta, o módulo de busca por peças processuais similares. Construí um corpus de artigos científicos para validar a arquitetura antes de migrar para os documentos reais (pareceres, editais e atas), que dependem de coleta via LAI e de anotação própria.

A coleção foi construída a partir da API OpenAlex em duas etapas: (i) coleta de artigos em inglês sobre IA aplicada a procurement e legal NLP; (ii) coleta complementar de artigos em português sobre licitações, direito administrativo e auditoria governamental. A inclusão de documentos em português é motivada pelo fato de que o domínio-alvo (compras públicas brasileiras, Lei 14.133/2021) produz literatura predominantemente em português.

A segunda etapa exigiu uma busca prévia: quais bases e periódicos brasileiros publicam sobre o cruzamento entre tecnologia e administração pública? Conduzimos essa

busca com apoio do Gemini (Deep Research) e verificamos os resultados manualmente, o que definiu as palavras-chave em português. A coleta usou a API OpenAlex, que indexa periódicos brasileiros e dá, numa única interface, acesso amplo à produção nacional sobre o tema. Foi a escolha certa para esta etapa: gratuita, sem rate limit agressivo e com boa cobertura do domínio.

Quanto à conformidade com a Seção 5 do enunciado: a OpenAlex e o arXiv constam entre as fontes explicitamente permitidas, e a BDTD (Biblioteca Digital Brasileira de Teses e Dissertações, do Ibict) foi adotada como fonte equivalente para a cobertura em português, mediante aprovação do professor. Nenhuma coleção pré-pronta de *benchmark* de IR (e.g., BEIR, MS MARCO) foi usada como coleção principal; a coleção foi inteiramente construída e documentada para este trabalho.

Incluímos também o arXiv, e o resultado foi revelador. Buscas por frase exata sobre o tema retornaram apenas 42 artigos on-topic. O arXiv é forte em aprendizado de máquina, mas raso em compras públicas e direito administrativo brasileiro. Esse vazio não é uma falha da coleta. É a própria lacuna que motiva a pesquisa de mestrado: há muita IA e muita licitação, mas pouco no cruzamento dos dois.

Uma nota sobre o formato dos dados. O campo identificador de cada documento chama-se `arxiv_id`. O nome é herança do material de apoio do professor (o notebook de coleta do arXiv). Mantivemos o nome por compatibilidade, mas ele guarda o id da fonte de origem: id do arXiv para artigos do arXiv, id da OpenAlex (prefixo `w`) para a OpenAlex e id da BDTD para as teses. Um campo `source` registra a proveniência de cada documento.

As bases governamentais mapeadas (PNCP, Compras.gov.br, TCU, LexML) e os pareceres obtidos via LAI não entram nesta coleção. Elas são o corpus-alvo da etapa de mestrado, quando o foco deixa de ser artigos científicos e passa a ser peças processuais reais. Esses documentos têm uma natureza própria. O PNCP e os sistemas de compras entregam cada processo com um número variável de artefatos, que muda conforme o trâmite. Os resumos e textos introdutórios não seguem padronização real, o que abre espaço para inferências erradas na automação. É aí que o aprendizado semissupervisionado faz sentido: rotular tudo à mão é inviável pelo tamanho do conjunto, então parte-se de poucos rótulos e propaga-se o aprendizado para o resto.

- **Fontes:** OpenAlex (artigos de periódicos), BDTD/Ibict (teses e dissertações brasileiras) e arXiv (pré-prints)
- **Palavras-chave (EN):** “public procurement NLP”, “legal document classification”, “regulatory compliance automation”, entre outras
- **Palavras-chave (PT):** “licitação inteligência artificial”, “tribunal contas auditoria”, “processamento linguagem natural documentos jurídicos”, “contratação pública tecnologia”, entre outras
- **Janela temporal:** 2018–2026
- **Tamanho final:** 3.106 documentos (2.758 OpenAlex + 306 BDTD + 42 arXiv; 2.135 EN + 971 PT) após deduplicação

A distribuição temporal é equilibrada e o corpus cobre múltiplas subáreas: IA em direito, compliance, procurement, auditoria governamental e processamento de textos jurídicos.

3.2. Pré-processamento

O mesmo pipeline é aplicado a documentos e consultas, com detecção automática de idioma para seleção do stemmer adequado:

1. **Lowercase:** conversão para minúsculas.
2. **Tokenização:** expressão regular que mantém palavras alfabéticas com mais de 1 caractere.
3. **Stopwords:** lista NLTK bilíngue (inglês + português) expandida com termos genéricos de abstracts em ambos os idiomas.
4. **Detecção de idioma:** heurística baseada em palavras-marcador do português (“de”, “da”, “para”, “são”, etc.). Se 3 ou mais marcadores aparecem nas primeiras 50 palavras, o texto é classificado como português.
5. **Stemming:** Porter Stemmer para inglês; RSLP Stemmer para português (ambos do NLTK).

O texto indexado de cada documento é a concatenação de título e abstract. A abordagem bilíngue funciona assim: cada texto passa pelo detector de idioma e recebe o stemmer da sua língua (Porter para inglês, RSLP para português). As stopwords dos dois idiomas são removidas sempre. Com isso, BM25 e TF-IDF tratam PT e EN no mesmo índice, sem separar as subcoleções. O alcance, porém, é limitado. Uma consulta em português só recupera um documento em inglês quando os dois compartilham radicais após o stemming, o que costuma ocorrer só com nomes próprios e siglas. Para casar significado entre idiomas sem coincidência de termos, recorremos ao recuperador denso (Seção 3.5).

3.3. BM25 (recuperação esparsa)

Usamos a implementação `rank_bm25` (BM25Okapi) com os hiperparâmetros padrão da literatura: $k_1 = 1.5$ e $b = 0.75$ [Robertson and Zaragoza 2009]. A escolha segue Robertson e Zaragoza. Eles mostram que esses valores são robustos para coleções de tamanho moderado, sem precisar de ajuste empírico.

A pontuação BM25 para um documento d dada uma consulta q com termos $q_1, \dots, q_n$ é:

$$\text{score}(d, q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, d) \cdot (k_1 + 1)}{f(q_i, d) + k_1 \cdot (1 - b + b \cdot \frac{|d|}{\text{avgl}})} \quad (1)$$

Conexão com Naïve Bayes. BM25 e Naïve Bayes partem da mesma pergunta: qual a chance de um documento ser relevante, dados os termos da consulta? O Naïve Bayes responde assumindo que os termos são independentes entre si. O BM25 herda essa ideia. A componente IDF é o coração da ligação. Ela pesa cada termo pelo quanto ele distingue um documento relevante dos demais, o mesmo papel do log-odds que o Naïve Bayes calcula para cada palavra dada a classe. Termos raros valem mais porque carregam mais informação. Sobre essa base, o BM25 acrescenta dois ajustes que o Naïve Bayes puro não tem. O k_1 controla a saturação: a décima ocorrência de um termo agrega menos que a segunda, porque repetir não aumenta a relevância para sempre. O b corrige o tamanho do documento, para que um texto longo não pareça mais relevante só por conter mais palavras. Em resumo, o BM25 é um Naïve Bayes calibrado para ranquear.

3.4. KNN/TF-IDF (recuperação por vizinhos mais próximos)

O que é TF-IDF. O TF-IDF transforma cada documento em um vetor numérico. Cada posição do vetor é um termo do vocabulário. O valor combina dois fatores: TF, quantas vezes o termo aparece no documento, e IDF, quão raro o termo é no corpus inteiro. Um termo frequente naquele documento e raro nos demais recebe peso alto, porque é o que o caracteriza. Termos comuns a quase todos os textos recebem peso baixo. Documentos sobre o mesmo assunto terminam com valores parecidos nas mesmas posições, e seus vetores ficam próximos no espaço.

Construímos a matriz TF-IDF com o `TfidfVectorizer` do `scikit-learn`. Os cortes `min_df=2` e `max_df=0.95` descartam termos que aparecem em um só documento e termos presentes em mais de 95% deles, que não ajudam a distinguir nada. A busca devolve os K documentos de maior similaridade de cosseno com a consulta.

Conexão com a disciplina: O uso de KNN aqui difere da classificação vista em aula em um aspecto conceitual: em vez de encontrar os K vizinhos mais próximos e votar uma classe, devolvemos os K documentos mais similares como ranking de resposta à consulta. O algoritmo é o mesmo (busca por proximidade em espaço vetorial), mas a saída é uma lista ranqueada e não um rótulo. A ponderação TF-IDF conecta com a discussão de Naïve Bayes: o componente IDF é análogo à probabilidade a priori de observar cada termo, penalizando termos frequentes e valorizando termos discriminativos.

Escolha da similaridade: Optamos pela similaridade do cosseno em vez da distância euclidiana porque o cosseno normaliza pelo comprimento dos vetores, tornando a métrica invariante ao tamanho do documento. Dois abstracts sobre o mesmo tema, um curto e um longo, terão vetores na mesma direção (alto cosseno) mesmo com magnitudes diferentes (alta distância euclidiana).

3.5. Recuperador denso com embeddings

O TF-IDF casa termos exatos. Ele não sabe que “licitação” e “procurement” falam da mesma coisa. Para cobrir esse caso, adicionamos um terceiro recuperador, baseado em embeddings. Um embedding é um vetor denso produzido por uma rede neural pré-treinada, no qual textos de significado parecido ficam próximos mesmo sem compartilhar palavras. Usamos o modelo multilíngue `paraphrase-multilingual-MiniLM-L12-v2`, que mapeia português e inglês no mesmo espaço. Cada documento e cada consulta viram um vetor de 384 dimensões, e a busca devolve os K vizinhos de maior cosseno. O uso de modelos prontos é permitido (a aula não cobre o treinamento deles), então implementamos apenas a codificação e a busca. A motivação é direta: resolver a recuperação cross-lingual que o TF-IDF não alcança.¹

3.6. Módulos de aprofundamento

Além do pipeline obrigatório, implementamos os cinco módulos da Seção 4 do enunciado. O Mestrado exige só um. Fizemos os cinco por interesse próprio em comparar as abordagens. Cada módulo é avaliado na Seção 4.

¹Hardware: Intel Core i7-12650H (16 threads), Debian 13, Python 3.13, execução em CPU (sem GPU). A codificação dos 3.106 documentos levou cerca de 3,6 minutos; BM25 e TF-IDF rodam em segundos.

M5: ranking híbrido (RRF). O RRF [Cormack et al. 2009] combina rankings sem normalizar scores:

$$\text{score}_{\text{RRF}}(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)} \quad (2)$$

onde $k = 60$ (constante padrão) e R reúne os rankings do BM25 e do recuperador denso. A vantagem é não depender de calibração entre escalas: o BM25 varia de 0 a cerca de 20 e o cosseno de 0 a 1, mas o RRF olha só a posição. É um ensemble. Cada sistema vota pelo lugar que deu ao documento, e juntar votos de modelos com vieses diferentes reduz o erro, como na combinação de classificadores.

M1: re-ranking supervisionado. Treinamos uma Regressão Logística para reordenar o top-100 do BM25. As features de cada par (consulta, documento) são cinco: score BM25, cosseno TF-IDF, similaridade densa, sobreposição de termos e ano. O rótulo vem dos qrels. Para não treinar e testar na mesma consulta, usamos validação leave-one-query-out: o modelo treina em 14 consultas e reordena a 15^a. Liga à aula de classificação supervisionada.

M2: agrupamento dos resultados. Aplicamos K-means sobre o top-30 de uma consulta, no espaço dos embeddings. O número de grupos é escolhido pela silhueta. Cada grupo é descrito pelos seus termos mais frequentes, formando facetas temáticas. Liga às aulas de agrupamento de dados.

M3: expansão de consulta por regras de associação. Tratamos cada documento como uma transação de termos. Para cada termo da consulta, mineramos regras $\{A\} \Rightarrow \{B\}$ com suporte, confiança e lift acima de um limiar. O lift descarta termos genéricos, que coocorrem com quase tudo. Os termos consequentes entram na consulta, que é re-executada no BM25. Liga à aula de regras de associação.

M4: otimização de hiperparâmetros. Fizemos grid search sobre $k_1 \in \{1,2; 1,5; 2,0\}$ e $b \in \{0,5; 0,75; 1,0\}$ do BM25, maximizando o MAP no conjunto de avaliação. A configuração vencedora e a tabela completa de desempenho constam na Seção 4. Liga à aula de algoritmos de otimização.

3.7. Avaliação

3.7.1. Consultas de teste

Criamos 15 consultas representativas do domínio (Tabela 1). Elas não são aleatórias. Espelham as subáreas da proposta de mestrado: classificação de documentos (q01, q15), conformidade e compliance (q02, q08, q11), análise de editais e contratos (q03, q04, q13), fraude e auditoria (q05, q12), apoio à decisão, avaliação e grafos (q06, q07, q09) e o recorte central da pesquisa, a classificação semissupervisionada com poucos rótulos (q10). Variamos a especificidade de propósito: algumas amplas, outras finas.

A divisão entre 10 consultas em inglês e 5 em português também é deliberada. A literatura de método (NLP, IR, ML) é quase toda em inglês, e é nela que estão os trabalhos técnicos. As cinco consultas em português miram o domínio brasileiro: Lei 14.133, tribunal de contas, contratos públicos. A divisão testa o sistema nos dois eixos que o problema real combina: a técnica, em inglês, e a aplicação, em português.

Tabela 1. Consultas de teste usadas na avaliação (10 EN + 5 PT)

ID	Idioma	Consulta
q01	EN	public procurement document classification machine learning
q02	EN	legal compliance checking NLP automated verification
q03	EN	tender document analysis natural language processing
q04	EN	government contract clause extraction deep learning
q05	EN	procurement fraud detection anomaly bidding collusion
q06	EN	e-procurement automation decision support system
q07	EN	bid evaluation criteria similarity neural networks
q08	EN	regulatory compliance verification document NLP
q09	EN	knowledge graph public procurement legislation
q10	EN	semi-supervised classification legal text few labels
q11	PT	licitação análise conformidade inteligência artificial
q12	PT	tribunal contas auditoria automatizada documentos
q13	PT	contratos públicos processamento linguagem natural
q14	PT	lei 14133 compras públicas tecnologia
q15	PT	classificação documentos administrativos aprendizado máquina

3.7.2. Construção dos qrels

Anotamos a relevância por pooling. Para cada consulta, unimos o top-10 de todos os sistemas (BM25, KNN, denso, RRF e os módulos), removemos duplicatas e julgamos cada documento na escala 0/1/2. O conjunto começou com 231 julgamentos manuais. Ao acrescentar o denso, o arXiv e os módulos, o pool cresceu e exigiu 212 julgamentos novos. Esses foram anotados com apoio de um classificador treinado nos 231 originais e revisados pelo autor, totalizando 443 julgamentos. A Seção 5.2 discute o que essa etapa revelou e por que ela é central para a pesquisa de mestrado.

Critério de relevância adotado: consideramos relevante (1) todo artigo que aborda diretamente a técnica ou domínio especificado na query, e altamente relevante (2) artigos que tratam exatamente do cruzamento entre a técnica de NLP/ML indicada e o domínio de procurement/legal da query.

Métricas reportadas: Precision@10 (P@10), Recall@10 (R@10), Mean Average Precision (MAP) e normalized Discounted Cumulative Gain (nDCG@10).

4. Resultados

O M1 (re-ranking supervisionado) é o melhor sistema: MAP 0,864 e P@10 0,740, acima do BM25 (MAP 0,830). Faz sentido, porque o M1 aprende a combinar os sinais dos outros recuperadores. O BM25 é um baseline forte, e o KNN/TF-IDF empata com ele em P@10. O recuperador denso e o RRF aparecem bem abaixo. Esse número pede cuidado na leitura. Ele diz mais sobre como construímos o gabarito do que sobre a qualidade do denso, e a Seção 5.2 explica por quê.

4.1. Análise qualitativa

O re-ranking em ação (q01). Na consulta “public procurement document classification machine learning”, o M1 melhora o BM25 em toda a linha: P@10 de 0,90 para 1,00,

Tabela 2. Resultados médios sobre 15 consultas (corpus de 3.106 documentos, 443 julgamentos). M2 e M4 não geram ranking comparável e são reportados à parte.

Sistema	P@10	R@10	MAP	nDCG@10
BM25	0.727	0.644	0.830	0.791
KNN/TF-IDF	0.720	0.639	0.740	0.697
Denso (embeddings)	0.240	0.172	0.180	0.306
RRF (BM25+denso)	0.580	0.456	0.552	0.642
M1 (re-ranking)	0.740	0.651	0.864	0.794
M3 (expansão)	0.567	0.515	0.608	0.643

MAP de 0,78 para 0,89 e nDCG de 0,90 para 0,96. O classificador aprende a combinar score BM25, cosseno, similaridade densa e sobreposição de termos, e empurra para o topo os documentos certos. É o ganho que se espera de um re-ranking supervisionado.

O casamento exato ainda resolve muito (q14). A consulta em português “lei 14133 compras públicas tecnologia” tem P@10=1,00 no BM25. Quando a consulta traz o termo exato do domínio, como o número da lei, o esparsos acerta sem precisar de semântica.

O denso e o limite do gabarito (q07). O recuperador denso pontua baixo em quase todas as consultas, chegando a P@10=0,00 em q07. Mas, ao ler os resultados, vê-se que ele recupera documentos plausíveis. Em q01, ele traz a dissertação “Classificação automática de documentos” (similaridade 0,64), que o nosso gabarito marcou como não-relevante. O problema não está no denso. Está no gabarito: ele foi montado a partir de um pool majoritariamente lexical, e os documentos que só o denso encontra ficaram de fora ou foram subjulgados. A próxima seção trata disso.

Módulos M2 e M4. O M2 (agrupamento) separou o top-30 de uma consulta em grupos coerentes, escolhidos por silhueta, com facetas temáticas distintas. O M4 (otimização) varreu a grade de k_1 e b do BM25 e encontrou a melhor configuração no conjunto de avaliação. As saídas completas estão nos apêndices e no repositório.

5. Discussão

5.1. Trade-offs entre recuperação esparsa e densa

O melhor sistema foi o M1. O re-ranking supervisionado lidera em todas as métricas (MAP 0,864, P@10 0,740), porque combina os sinais dos demais recuperadores em vez de depender de um só. O BM25 é o baseline forte (MAP 0,830), e o KNN/TF-IDF empata com ele em P@10 (0,720 contra 0,727). A subcoleção em português, mais diversa, ajuda o TF-IDF a competir com o esparsos.

O denso e o RRF ficaram abaixo, e isso merece explicação. Pelos números, o denso (P@10 0,240) e o RRF (0,580) decepcionam. Mas a próxima seção mostra que o problema está no gabarito, não nos modelos. A barreira de idioma também pesa: o stemmer bilíngue casa pouco entre PT e EN, e era o denso multilíngue que deveria cobrir esse vão. Para medir esse ganho, porém, é preciso um gabarito que enxergue os relevantes que o denso encontra.

5.2. O desafio da anotação de relevância

Ao adicionar o denso, o arXiv e os módulos, o pool de avaliação cresceu. Só o denso trouxe 120 documentos novos ao top-10. Anotar tudo à mão, relendo cada par consulta-documento, é caro. Recorremos a um classificador treinado nos 231 julgamentos originais para sugerir os 212 rótulos novos, e os revisamos. Esse classificador aprendeu com um gabarito de origem lexical, então tende a marcar como não-relevante justamente os documentos que o denso encontra por significado. O resultado é que o denso é penalizado por achar itens certos que o gabarito não reconhece.

O fenômeno é conhecido. Zobel [Zobel 1998] mostrou que documentos fora do pool, contados como não-relevantes, enviesam a comparação contra sistemas que recuperam itens novos. Voorhees [Voorhees 2000] mostrou que julgamentos de relevância variam entre anotadores, mas ainda permitem comparar sistemas. Sanderson [Sanderson 2010] descreve como construir coleções de teste mais sólidas. A relevância graduada que adotamos segue Järvelin e Kekäläinen [Järvelin and Kekäläinen 2002].

Apresentamos os números como eles são. Eles refletem o método e o conhecimento que tínhamos no momento, não um veredito final sobre o denso. O caminho de melhoria é claro: pool mais profundo, mais de um anotador com acordo medido, e julgamento por leitura, não por proxy lexical.

E aqui está o elo com a pesquisa de mestrado. Anotar relevância à mão é lento, subjetivo e não escala. Sentimos isso ao construir 443 julgamentos para apenas 15 consultas. No domínio licitatório, com volume muito maior e sem dados rotulados, o custo se torna proibitivo. É essa a motivação do mestrado: aprendizado semissupervisionado para classificar e recuperar com poucos rótulos, reduzindo a dependência da anotação manual.

5.3. Conexões com a disciplina

Os componentes mapeiam diretamente para tópicos vistos em sala. BM25 e TF-IDF ligam ao paradigma probabilístico do Naïve Bayes (IDF como log-odds). O recuperador denso e o KNN ligam à busca por vizinhos em espaço vetorial; a diferença para a aula é a saída, um ranking em vez de um rótulo. O RRF liga ao ensemble de classificadores. E os módulos M1 a M4 ligam, na ordem, à classificação supervisionada, ao agrupamento de dados, às regras de associação e aos algoritmos de otimização.

5.4. Limitações

(i) O gabarito tem viés de pooling, e parte dos julgamentos novos foi sugerida por classificador e revisada, não anotada do zero (Seção 5.2). (ii) A avaliação usa 15 consultas e um único anotador, sem acordo inter-anotador; o M4 otimiza sobre esse mesmo conjunto, com risco de superajuste. (iii) O corpus mistura subáreas adjacentes (blockchain, ética de IA), o que introduz ruído. (iv) O recuperador denso usa um modelo pré-treinado genérico; um modelo jurídico em português tende a ir melhor.

6. Conclusão

Implementamos e avaliamos um sistema de recuperação híbrido para artigos sobre IA em compras públicas. O corpus é bilíngue, com 3.106 documentos: artigos da OpenAlex (inglês e português), teses e dissertações da BDTD e pré-prints do arXiv. O melhor

sistema foi o re-ranking supervisionado (M1), com MAP 0,864. Mais importante que o ranking, porém, foi uma lição de método. O recuperador denso ficou subavaliado porque o gabarito, de origem lexical, não reconhece os relevantes que ele encontra por significado. Isso expõe o gargalo da anotação manual de relevância. Como trabalho futuro, pretendemos (i) reconstruir o gabarito com pool mais profundo e mais de um anotador, para medir o denso de forma justa; (ii) incorporar dados primários das APIs governamentais (PNCP, Compras.gov.br, TCU, LexML) e pareceres via LAI; e (iii) avançar para a classificação semissupervisionada de textos licitatórios, foco do mestrado².

Uma extensão conceitual está em prototipação, em ramo separado do repositório (`v2-reference-finder`), sem impacto sobre os resultados aqui reportados. Ela reaproveita o núcleo de recuperação como assistente de referências bibliográficas. O texto de um artigo em elaboração entra como consulta longa. Dele extraímos palavras-chave que alimentam a busca híbrida. A saída são referências em formato BibTeX e uma análise de lacunas: temas presentes no texto, mas sem cobertura no corpus. O recorte transpõe o problema de recuperação deste trabalho para o apoio à revisão de literatura, em continuidade com a pesquisa de mestrado.

Para fins de reprodução e avaliação, o sistema completo (pipeline, dados e relatório) está empacotado em container e disponível para teste interativo por um terminal web no navegador³.

Declaração de uso de IA generativa

Conforme Resolução nº 455-COUN/UFMS (BO-UFMS ID 581705; Art. 6º, V e Art. 12, Parágrafo único), declara-se o uso das seguintes ferramentas de IA como apoio durante a elaboração deste trabalho:

- **Gemini (Google, funcionalidade Deep Research):** usado para pesquisa exploratória de fontes e bases de dados acadêmicas em língua portuguesa. A especificidade do domínio (compras públicas brasileiras, Lei 14.133/2021) e a escassez de artigos no ArXiv sobre o tema motivaram a busca por bases complementares. O Gemini auxiliou na identificação de periódicos e repositórios brasileiros relevantes, cujos resultados foram avaliados criticamente e verificados manualmente pelo autor.
- **Claude/Kiro (Anthropic):** apoio na implementação de scripts de coleta e pipeline, sugestões de hiperparâmetros e estruturação do relatório.

Em ambos os casos, as ferramentas serviram como apoio instrumental. As decisões de projeto (escolha do tema, definição de queries, critérios de relevância), a anotação manual dos qrels, a análise crítica dos resultados e a redação argumentativa do relatório são integralmente do autor. Todo código gerado com auxílio de IA foi revisado, testado e adaptado antes da incorporação.

²Vídeo de apresentação e repositório: ver arquivo LINKS.txt.

³O endereço de acesso (terminal web, sem necessidade de instalar nada) está no arquivo LINKS.txt da submissão. O acesso conduz diretamente ao ambiente isolado do trabalho, onde `make eval` reproduz as métricas aqui reportadas e `make demo` executa uma consulta. Um segundo endereço dá acesso ao protótipo `v2-reference-finder`.

Referências

- Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., and Androutsopoulos, I. (2020). LEGAL-BERT: The muppets straight out of law school. In *Findings of EMNLP*, pages 2898–2904.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of SIGIR*, pages 758–759.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., and Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*.
- Järvelin, K. and Kekäläinen, J. (2002). Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446.
- Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., and Yih, W.-t. (2020). Dense passage retrieval for open-domain question answering. In *Proceedings of EMNLP*, pages 6769–6781.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Lin, J. (2021). A proposed conceptual framework for a representational approach to information retrieval. *SIGIR Forum*, 55(2):1–29.
- Manning, C. D., Raghavan, P., and Schütze, H. (2008). *Introduction to Information Retrieval*. Cambridge University Press.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- Sanderson, M. (2010). Test collection based evaluation of information retrieval systems. *Foundations and Trends in Information Retrieval*, 4(4):247–375.
- Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., and Gurevych, I. (2021). BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *NeurIPS Datasets and Benchmarks*.
- Voorhees, E. M. (2000). Variations in relevance judgments and the measurement of retrieval effectiveness. *Information Processing & Management*, 36(5):697–716.
- Zobel, J. (1998). How reliable are the results of large-scale information retrieval experiments? *Proceedings of ACM SIGIR*, pages 307–314.

Apêndice A: Average Precision por consulta

A Tabela 3 traz a AP de cada sistema por consulta. Ela mostra de forma transparente o efeito discutido na Seção 5.2: o denso pontua perto de zero em consultas como q12 e q15, onde os documentos que ele recupera não constam como relevantes no gabarito.

Tabela 3. Average Precision (AP) por consulta.

qid	BM25	KNN	Denso	RRF	M1	M3
q01	0.782	0.693	0.272	0.630	0.891	0.647
q02	0.590	0.738	0.189	0.448	0.734	0.571
q03	0.759	0.692	0.294	0.683	0.824	0.478
q04	0.813	0.676	0.349	0.702	0.855	0.484
q05	0.850	0.758	0.203	0.570	0.909	0.401
q06	0.750	0.423	0.200	0.606	0.759	0.344
q07	0.729	0.436	0.028	0.392	0.714	0.282
q08	0.788	0.720	0.301	0.661	0.886	0.525
q09	0.927	0.895	0.190	0.555	0.977	0.445
q10	0.713	0.805	0.154	0.614	0.795	0.753
q11	1.000	0.982	0.012	0.595	1.000	0.810
q12	0.952	0.798	0.001	0.433	0.954	0.864
q13	1.000	0.700	0.250	0.532	0.833	1.000
q14	0.959	0.919	0.253	0.705	0.987	0.672
q15	0.841	0.861	0.000	0.149	0.841	0.841

Apêndice B: Otimização do BM25 (M4)

Grid search de k_1 e b , com MAP no conjunto de avaliação. A melhor configuração ($k_1 = 2,0$, $b = 0,5$) eleva o MAP de 0,830 (padrão) para 0,851.

Tabela 4. MAP por configuração do BM25.

k_1	b	MAP	k_1	b	MAP	k_1	b	MAP
1.2	0.50	0.817	1.5	0.50	0.829	2.0	0.50	0.851
1.2	0.75	0.816	1.5	0.75	0.830	2.0	0.75	0.831
1.2	1.00	0.781	1.5	1.00	0.774	2.0	1.00	0.782

Apêndice C: Agrupamento dos resultados (M2)

Para a consulta “lei 14133 compras públicas tecnologia”, o K-means sobre o top-30 (espaço dos embeddings) escolheu $k = 2$ pela silhueta. As facetas, descritas pelos termos mais frequentes de cada grupo:

- **Grupo 0 (marco legal e processo):** público, lei, compra, processo, contrato, licitação.
- **Grupo 1 (tecnologia e sustentabilidade):** compra, público, análise, tecnologia, sustentável, federal.

O pool completo de anotação, com sugestões, sinais e julgamentos, está disponível como planilha no repositório⁴.

⁴https://github.com/luizfpq/ufms-facom-ia-2026.1-t1/blob/main/eval/pool_revisao.xlsx